

```
import requests
import urllib.request
import time
import os
import warnings
from bs4 import BeautifulSoup
from google.colab import drive
drive.mount('/content/drive')
```

Mounted at /content/drive

Program ini dibuat untuk melakukan web scraping dari website Mahkamah Agung, khususnya untuk mengambil daftar link putusan pengadilan dari PN Wonogiri kategori "pidana umum". Hasil scraping disimpan ke dalam sebuah file .txt di Google Drive.

Pertama, impor beberapa library:

- requests untuk mengirim request HTTP ke website.
- urllib.request sebenarnya tidak terpakai di sini, tapi biasanya digunakan untuk download konten dari URL.
- time untuk mengukur lama proses scraping.
- os juga tidak terpakai langsung, biasanya dipakai untuk operasi file/direktori.
- warnings untuk mengabaikan warning.
- BeautifulSoup dari bs4 untuk parsing HTML.
- google.colab.drive untuk mount Google Drive agar bisa menyimpan hasil ke dalam file.

```
def getURLfromWeb(url):

    response = requests.get(url, verify=False) # ambil halaman web tanpa verifikasi SSL
    print(response)

    htmlCode1 = BeautifulSoup(response.text, 'html.parser') # parsing HTML
    result1=htmlCode1.findAll('a') # cari semua tag <a> (hyperlink)

    urlHasil=[]
    for eachResult1 in result1:
        cariURLawal=str(eachResult1).find('https://putusan3.mahkamahagung.go.id/direktori/putusan/')
        cariURLakhir=str(eachResult1).find('html">Putusan') + 4
        #print(cariURLakhir)
        if cariURLawal == 9 and cariURLakhir >= 4:
            #print(str(eachResult1)[cariURLawal:cariURLakhir])
            cariURL=str(eachResult1)[cariURLawal:cariURLakhir]
            urlHasil.append(cariURL)

    print(urlHasil)
    return(urlHasil)
```

Lalu pada fungsi getURLfromWeb(url) yang bertugas mengambil semua link putusan dari sebuah halaman.

```
def getURLfromWeb(url):

    response = requests.get(url, verify=False) # ambil halaman web tanpa verifikasi SSL
    print(response)

    htmlCode1 = BeautifulSoup(response.text, 'html.parser') # parsing HTML
    result1=htmlCode1.findAll('a') # cari semua tag <a> (hyperlink)
```

Dari semua tag a, kemudian akan dicari yang mengandung link putusan dengan pola <https://putusan3.mahkamahagung.go.id/direktori/putusan/> dan berakhiran html">Putusan.

```
urlHasil=[]
for eachResult1 in result1:
    cariURLawal = str(eachResult1).find('https://putusan3.mahkamahagung.go.id/direktori/putusan/')
    cariURLakhir = str(eachResult1).find('html">Putusan') + 4

    if cariURLawal == 9 and cariURLakhir >= 4:
        cariURL = str(eachResult1)[cariURLawal:cariURLakhir]
        urlHasil.append(cariURL)
```

```

def main():

    warnings.filterwarnings('ignore')

    file_path = "/content/drive/MyDrive/Semester_5/Information_Extraction/hasilListURLPage.txt" # tempat untuk menyimpan

    url1 = 'https://putusan3.mahkamahagung.go.id/direktori/index/pengadilan/pn-wonogiri/kategori/pidana-umum-1.html'
    url2 = 'https://putusan3.mahkamahagung.go.id/direktori/index/pengadilan/pn-wonogiri/kategori/pidana-umum-1/page/'

    listHasil = []
    ulang = 20

    startTime = time.time()
    file_hasil = open(file_path, "w", encoding='UTF8') # membuka file .txt nya

    for i in range(ulang):

        if i == 0:
            url = url1
            print(1)
        else:
            n=i+1
            url = url2+str(n)+'.html'
            print(2)

        listHasil = getURLfromWeb(url)

        for listURL in listHasil:
            file_hasil.write(listURL+"\n")

    file_hasil.close()
    endTime = time.time()
    print(listHasil)
    print('Time Processing : ', endTime-startTime, ' Second')

main();

```

```

1
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaf08e2d6ae933ca854d313730333336.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaf057b29f09e62e9211303930383333.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaf0564dbb162e56a446313433333439.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaf03b993e4846e4896e313435363230.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaefffeb9e1b1b26ac37313631343530.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaef9287f0dec2f88d81313131363433.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaef4a234a787564b636303831343530.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaef0c4a99236e7eb6a6313532303030.html', 'https://putusan3.mahka
2
<Response [502]>
[]
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaeed699feb839dc9873303732353039.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaee8e513608db0cbc4a303734393534.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaee42212fa68222b882303835343339.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaee04e91bf3900a9621313130393333.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaedada8520fdafa6b44b313031363336.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaed753cdbac90e8829313530363136.html', 'https://putusan3.mahka
2
<Response [200]>
[ 'https://putusan3.mahkamahagung.go.id/direktori/putusan/zaed3949a543a71c9540303830363338.html', 'https://putusan3.mahka

```

```

2
<Response [200]>
['https://putusan3.mahkamahagung.go.id/direktori/putusan/zaed04d00d14f818948c313332353133.html', 'https://putusan3.mahka
2
<Response [200]>
['https://putusan3.mahkamahagung.go.id/direktori/putusan/zaecc6a227ed1f7e95c2313032303239.html', 'https://putusan3.mahka
2
<Response [200]>
['https://putusan3.mahkamahagung.go.id/direktori/putusan/zaec8edee08402ee31d4213121242129.html', 'https://putusan3.mahka

```

Kemudian, fungsi utama main() berfungsi untuk mengatur scraping untuk banyak halaman sekaligus.

```
file_path = "/content/drive/MyDrive/Semester_5/Information_Extraction/hasilListURLPage.txt"
```

File hasil akan disimpan di Drive.

Kemudian di definisikan url1 sebagai halaman pertama, sedangkan url2 sebagai template untuk halaman berikutnya (page 2, page 3, dst).

```

url1 = '../kategori/pidana-umum-1.html'
url2 = '../kategori/pidana-umum-1/page/'

```

Kemudian variable ulang = 20, artinya scraping dilakukan sampai 20 halaman.

```
file_hasil = open(file_path, "w", encoding='UTF8')
```

Kemudian buka file .txt untuk menyimpan hasil.

```
file_hasil = open(file_path, "w", encoding='UTF8')
```

Lalu dengan for i in range(ulang): saya looping tiap halaman.

Kalau i == 0, saya ambil url1 (halaman pertama).

Kalau lebih dari 0, maka saya format url2+str(n)+'.html' (halaman ke-2 dst).

```

if i == 0:
    url = url1
else:
    n = i + 1
    url = url2 + str(n) + '.html'

```

Untuk setiap halaman, panggil getURLfromWeb(url) untuk mendapatkan list link putusan. Lalu hasilnya akan di tulis ke file .txt.

```

for listURL in listHasil:
    file_hasil.write(listURL + "\n")

```